

Desafio Final – Databricks – Upskill Tiller | Engenharia de Dados | T2

Esta atividade prática faz parte da reta final do programa Upskill Tiller – Engenharia de Dados. O objetivo é avaliar a capacidade dos membros de construir uma solução de dados ponta a ponta no Databricks, trabalhando com dados não estruturados e estruturados disponibilizados pelo portal de Dados Abertos da Câmara dos Deputados.

Prazo: 04/05/2026 - 12h

Fonte de dados (API): <https://dadosabertos.camara.leg.br/swagger/api.html>

Onde entregar? Enviar o Repositório do Git (deixar o repositório público) para os e-mails:

gionni.gomes@compasso.com.br; guilherme.assis@compasso.com.br; juan.nunes@compasso.com.br;
james.bombasar@compasso.com.br; adyna.ayana@compass.uol

Recomendações e Boas Práticas

Utilize a documentação e comunidade do Databricks para concluir o desafio do Fast Track. Será necessário pesquisas extras e estudar a API da Câmara dos Deputados para realizar a entrega.

Desenvolva a solução com as melhores práticas de desenvolvimento e conceitos fundamentais da Engenharia de Dados, considerando a futura manutenção e escalabilidade da solução.

Arquitetura de Dados

- Desenhar a arquitetura completa da solução, detalhando camadas (bronze, prata, ouro), fluxos de ingestão, processamento e controle de qualidade.
- É desejável a especificação de arquitetura ao qual foi optada e por qual motivo.

Modelagem e Otimização de Tabelas

- Ressaltamos a recomendação em seguir com a arquitetura medalhão
- Comparar e justificar diferentes modelos de tabelas (SCD Type 2, tabelas gold, fato/dimensão, etc.).
- Demonstrar métodos para rastrear a origem e evolução dos dados (exemplo: campos de auditoria, time travel ou logs detalhados).

Detecção de Padrões e Anomalias

- Realizar análises de outliers e score de anomalias, explicando a abordagem utilizada e decisões tomadas.

Documentação Técnica e Runbook

- Documentar todas as etapas dos pipelines (triggers, dependências, estratégias de recuperação).
- Incluir registro de decisões técnicas (origem dos dados, transformações e manutenção).

Resiliência e Recuperação

- Implementar pipelines automáticos com mecanismos de replay e reproprocessamento para cenários de falha.
- Elaborar registros/manuais de incidentes (runbooks) e estratégias de tolerância a falhas.

Carga Incremental

- Quando necessário, implementar soluções de carga incremental (sem detalhar endpoint, deixar livre para construção de hash, uso de ID, etc.).

Relacionamento entre Tabelas

- Indicar tabelas que se relacionam indicando seus relacionamentos (exemplo: eventos e votações).

Demais Pontos

- Dar preferência absoluta ao uso de recursos nativos do PySpark para ingestão, processamento e análises de forma mais performática e sobre as boas práticas da engenharia de dados.

- Fique à vontade para incrementar a solução com outros recursos, desde que justificados.

Sobre o desafio e entregáveis

1) Atlas das frentes parlamentares

Mapeamento completo das frentes ativas, seus membros e a interseção com partidos e UFs para revelar bancadas temáticas.

Entregas esperadas

- Tabela gold de frentes com membros, partido, UF e legislatura por frente
- Identificação das frentes com maior diversidade partidária (índice de Herfindahl)
- Deputados que participam de mais frentes — perfil e temas de interesse
- Sobreposição de membros entre frentes: quem está em frentes ideologicamente opostas?
- Evolução do número de frentes por tema entre legislaturas

Calendário analítico de eventos legislativos

Visão consolidada de todos os eventos (sessões, audiências, seminários) com presença de deputados e pauta.

Entregas esperadas

- Tabela gold de eventos com dim_orgao, dim_tipo_evento, dim_data
- Taxa de presença por deputado e por tipo de evento ao longo do ano
- Comparativo de frequência antes e depois de períodos eleitorais
- Densidade de eventos por semana e identificação de semanas sem atividade
- View pública com calendário de eventos futuros já agendados

Correlação entre frentes e votações

Entregas esperadas

- Verificar se deputados de uma mesma frente votam de forma mais alinhada do que seus colegas de partido.

Raio-X de gastos da CEAP por deputado

Pipeline completo de ingestão e análise das despesas da cota parlamentar com detecção de anomalias por fornecedor e categoria.

Entregas esperadas

- Ingestão incremental de /deputados/{id}/despesas com controle de paginação
- Tabela fato_despesas com dimensões: deputado, fornecedor, categoria, mês
- Score de anomalia: z-score por categoria × estado do deputado
- Ranking de fornecedores mais pagos com flags de CNPJ suspeito (consulta Receita)
- Relatório mensal automatizado com top 10 gastos por partido

Pipeline de auditoria de CPIs

Rastreamento completo do ciclo de vida de CPIs: criação, eventos, convocados, relatório final e desfecho.

Entregas esperadas

- Tabela específica de CPIs com timeline de eventos e membros por fase
- Join com proposicoes para identificar legislação derivada de cada CPI
- Análise de duração: CPIs que excederam prazo regimental e motivos
- Rede de convocados cruzada com entidades privadas (quando disponível em fontes abertas)
- Comparativo de produtividade: CPIs que geraram relatório vs. as que foram encerradas sem conclusão

Monitor de presença e absenteísmo parlamentar

Pipeline que cruza presença em eventos com votações perdidas, gerando score de engajamento por deputado.

Entregas esperadas

- Desenvolver uma visão sobre junção entre eventos e votações para medir ausências em votações
- Score de engajamento composto: presença × votações × discursos × requerimentos
- Detecção de padrão de ausência: deputados que faltam mais em votações específicas
- Série temporal de engajamento com queda após eventos críticos (escândalos, reeleição)
- Relatório automático mensal para cada deputado com percentile em relação à média

Desafios Opcionais

Streaming de votações com alertas em tempo real

Pipeline de micro-batch que detecta novas votações, classifica urgência e dispara notificações automáticas.

Entregas esperadas

- Job agendado a cada 10 min consumindo /votacoes com controle de offset por ID
- DLT pipeline Bronze→Prata→Ouro com expectativas de qualidade declarativas
- SLA dashboard: latência end-to-end, volume e taxa de erro por execução
- Runbook de incidentes com estratégia de replay e reprocessamento

CDC de tramitação: histórico completo de cada PL

Change Data Capture com SCD Type 2 para rastrear toda a evolução de status de proposições, permitindo reconstrução histórica via Time Travel.

Entregas esperadas

- Ingestão incremental de com criação de chaves de payload para CDC
- Tabela prata SCD Type 2: valid_from, valid_to, is_current por proposição
- Reconstrução do estado de qualquer PL em qualquer data via Delta Time Travel
- Tempo médio de tramitação por tipo, partido autor e comissão relatora
- Alertas automáticos ou registrar quando PL avança para Plenário ou é arquivado

O time responsável pelo Fast Track de Engenharia de Dados da Tiller deseja um bom desafio a todos.

Conte com a gente em todo o processo.

Boa sorte!